Gender Recognition by Voice

Zespół:

Mateusze Sperkowski

Szymon Rećko

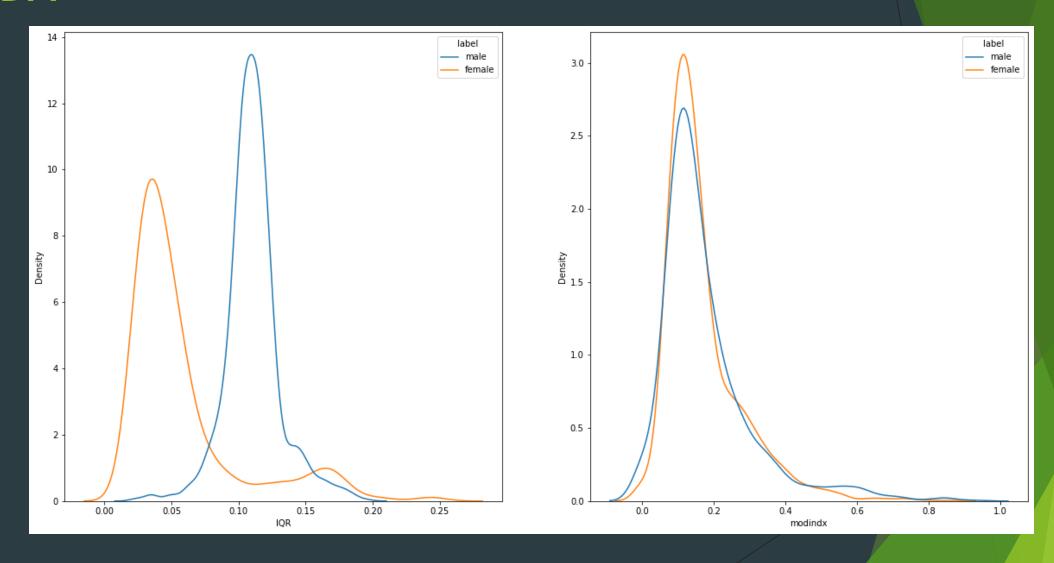
Dataset

- Oryginalne nagrania głosu zostały przetworzone za pomocą pakietu tuneR w R.
- Dostępne w zbiorze danych informacje:
- Cel Predykcji: Podpis płci (ilość danych 1:1).
- Częstotliwość głosu (kHz) oraz dane statystyczne (średnia, odchylenie standardowe, moda, kwartyle, kurtoza, skośność itd.).
- Ton podstawowy i dominujący (fundamental and dominant frequency), oraz ich dane statystyczne.
- Modulacja głosu.
- Zero brakujących danych.
- Wszystkie zmienne objaśniające są ciągłe.

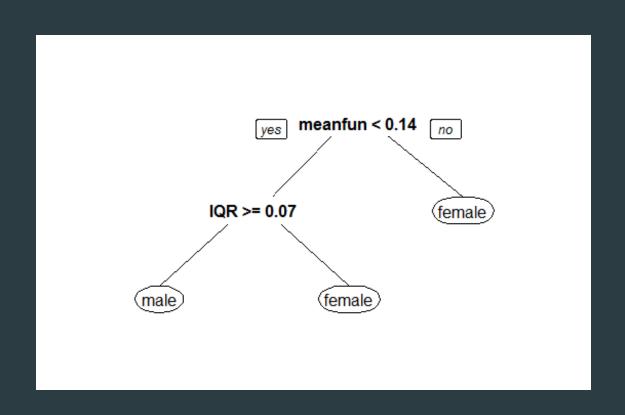
Dane pochodzą z: https://www.apispreadsheets.com/datasets/119

2 5 0 10 C 5 C 5 C 5 C 5 C 5 C 5 C 5 C 5 C 5 C			21 columns	
#	Column	Non-1	Null Count	Dtype
0	meanfreq	3168	non-null	float64
1	sd	3168	non-null	float64
2	median	3168	non-null	float64
3	Q25	3168	non-null	float64
4	Q75	3168	non-null	float64
5	IQR	3168	non-null	float64
6	skew	3168	non-null	float64
7	kurt	3168	non-null	float64
8	sp.ent	3168	non-null	float64
9	sfm	3168	non-null	float64
10	mode	3168	non-null	float64
11	centroid	3168	non-null	float64
12	meanfun	3168	non-null	float64
13	minfun	3168	non-null	float64
14	maxfun	3168	non-null	float64
15	meandom	3168	non-null	float64
16	mindom	3168	non-null	float64
17	maxdom	3168	non-null	float64
18	dfrange	3168	non-null	float64
19	modindx	3168	non-null	float64
20	label	3168	non-null	object

EDA



CART Model



Accuracy tego modelu na całym dataset wynosi 95.64(39)%

Feature Engineering

- ▶ RandomForest
- Polynomial features
- **▶** PCA
- ► NMF
- Standard scaler

Experiments

- Modele: SVM, LogReg, DecisionTree, NaiveBayes, RandomForest
- RandomizedSearchCV, GridSearchCV
- ► Test train split 33% do testu

Finalny model

- RandomForest z 50 drzewami.
- Użyte cechy: sd, Q25, IQR, sp.ent, sfm, mode, centroid, meanfun.

Accuracy: 0.9856

Recall: 0.9847

Precision: 0.9865

F1: 0.9856

ROC-AUC: 0.9856

Cross-val: 0.9646